

- 1) Há quantos casos neste conjunto de dados? Quantas variáveis? Para cada variável, identifique seu tipo de dado (por exemplo: categórica, contínua).

São 20000 casos.

Existem nove variáveis: *genhlth* (Qualitativa Ordinal), *exerany* (Qualitativa Nominal), *hlthplan* (Qualitativa Nominal), *smoke100* (Quantitativa Discreta), *height* (Quantitativa Contínua), *weight* (Quantitativa Contínua), *wt desire* (Quantitativa Contínua), *age* (Quantitativa Contínua), e *gender* (Qualitativa Nominal).

- 2) O que acontece quando você utiliza a função *summary* no conjunto de dados todo, isto é, sem especificar alguma variável? Experimente.

É feito o sumário numérico de todos os dados das variáveis que o cdc possui.

<i>genhlth</i>	<i>exerany</i>	<i>hlthplan</i>	<i>smoke100</i>	<i>height</i>
excellent:4657	Min. :0.0000	Min. :0.0000	Min. :0.0000	Min. :48.00
very good:6972	1st Qu.:0.0000	1st Qu.:1.0000	1st Qu.:0.0000	1st Qu.:64.00
good :5675	Median :1.0000	Median :1.0000	Median :0.0000	Median :67.00
fair :2019	Mean :0.7457	Mean :0.8738	Mean :0.4721	Mean :67.18
poor : 677	3rd Qu.:1.0000	3rd Qu.:1.0000	3rd Qu.:1.0000	3rd Qu.:70.00
	Max. :1.0000	Max. :1.0000	Max. :1.0000	Max. :93.00
<i>weight</i>	<i>wt desire</i>	<i>age</i>	<i>gender</i>	
Min. : 68.0	Min. : 68.0	Min. :18.00	m: 9569	
1st Qu.:140.0	1st Qu.:130.0	1st Qu.:31.00	f:10431	
Median :165.0	Median :150.0	Median :43.00		
Mean :169.7	Mean :155.1	Mean :45.07		
3rd Qu.:190.0	3rd Qu.:175.0	3rd Qu.:57.00		
Max. :500.0	Max. :680.0	Max. :99.00		

- 3) Crie um sumário numérico para *height* (altura) e *age* (idade), e calcule o intervalo interquartilico para cada um. Calcule a distribuição de frequência relativa para *gender* e *exerany*. Quantos homens compõem a amostra? Qual proporção da amostra diz estar com saúde excelente?

<i>height</i>	<i>age</i>
Min. :48.00	Min. :18.00
1st Qu.:64.00	1st Qu.:31.00
Median :67.00	Median :43.00
Mean :67.18	Mean :45.07
3rd Qu.:70.00	3rd Qu.:57.00
Max. :93.00	Max. :99.00

$$IIQ_{altura} = Q_3 - Q_1 = 70 - 64 = 6;$$

$$IIQ_{idade} = Q_3 - Q_1 = 57 - 31 = 26.$$

A amostra é composta por 9569 homens e 10431 mulheres.

$$Freq\ rel_{gên\ fem} = \frac{10431}{20000} = 0,52155; \text{ portanto}$$

$$Freq\ rel_{gên\ mas} = 1 - Freq\ rel_{gên\ fem} = 0,47845.$$

$$Freq\ rel_{exe\ sim} = \frac{14914}{20000} = 0,7457; \text{ portanto } Freq\ rel_{exe\ não} = 1 - Freq\ rel_{exe\ sim} = 0,2543.$$

A proporção de pessoas que diz estar com a saúde excelente é de $\frac{4657}{20000} = 0,23285$.

- 4) O que o gráfico de mosaico revela sobre os hábitos de fumar e gênero?


O gráfico de mosaico mostra de uma forma mais visual que, na amostra, mais pessoas do gênero masculino fumaram pelo menos 100 cigarros do que pessoas do gênero feminino.



- 5) Crie um novo objeto denominado *under23_and_smoke* (ou, se preferir, *abaixo23_e_fuma*) que contém todas as observações dos respondentes com menos de 23 anos que fumaram pelo menos 100 cigarros ao longo de sua vida. Escreva o comando que você utilizou para criar o novo objeto como resposta para esse exercício.

`abaixo23_e_fuma = subset(cdc, cdc$smoke100 == 1 & cdc$age < 23)`

- 6) O que este gráfico de caixas mostra? Escolha outra variável categorial do conjunto de dados e verifique como ela se relaciona ao IMC. Liste a variável que você escolheu, por que você pensou que ela poderia ter relação com o IMC e indique o que o gráfico parece sugerir.



O gráfico de caixas mostra o primeiro e terceiro quartis, e mediana das informações que estão sendo analisadas, que no caso são a IMC x Saúde. Mostrando também os Limites Superior e Inferior dos dados comparados.

Pensei que a idade poderia afetar diretamente o IMC, já que a altura e o peso de uma pessoa vão variando com conforme o indivíduo vai envelhecendo. Desse modo, o gráfico mostra que na amostra existem muitas pessoas que possuem o IMC muito maior do que o limite superior, principalmente as pessoas com as idades entre 18 e 60 anos.