


Exercício 1: Vamos dar uma olhada na distribuição da área em nossa população de vendas de casas calculando algumas estatísticas sumárias e criando um histograma usando as funções `summary()` e `hist()`, respectivamente. Descreva a distribuição da população.




Nos dados da população de vendas de casas que temos que a maior frequência na sua distribuição de área fica entre 1000 e 2000 pés quadrados. O valor do Primeiro Quartil é 1126 e o Terceiro é 1743, com Média de 1500.

Quanto mais a distribuição da área aumenta, menor é a frequência na população e poucas casas que possuem menos 500 pés quadrados.

Além de haver uma grande variação entre áreas das casas, já que a menor possui 334 pés quadrados,

enquanto a maior casa possui 5642 pés quadrados. Ela é assimétrica a esquerda.

Exercício 2: Descreva a distribuição desta amostra. Como ela se compara à distribuição da população?



A distribuição da amostra tem o mínimo de 816 pés quadrados e o máximo é de 2814. O valor do Primeiro Quartil é 1143 e o Terceiro é 1760, com Média de 1500. Sendo que possui uma concentração entre 1000 e 1250 pés quadrados. Comparado com a distribuição da população, a da amostra é, mais distribuída, mas ainda possui uma frequência parecida, já que, assim com na população total, a maior parte está presente entre 1000 e 2000 pés quadrados. Contudo, os polos

da amostra têm uma frequência maior que a população. Ela é assimétrica a esquerda.

Exercício 3: Se estamos interessados em estimar a área habitável média nas casas da cidade de Ames utilizando esta amostra, qual estatística você recomendaria? Calcule e reporte a sua estimativa.

Eu utilizaria a média amostral

$$\bar{X}_{50} = \frac{1}{50} \sum_{i=1}^{50} X_i = 1514,58$$

Exercício 4: Dependendo de quais foram as 50 casas sorteadas, ou seja, com uma amostra de menos de 3% da população, sua estimativa pode estar um pouco acima ou abaixo da média populacional verdadeira de 1500 pés quadrados. Você acha que obteve uma boa estimativa? Você acha que seus colegas obtiveram uma estimativa melhor ou pior que a sua?

Acho que a estimativa foi boa, já que, mesmo sendo uma amostra bem pequena, ela foi retirada aleatoriamente, sendo assim ela pode ter se aproximado da média real. Como a frequência está concentrada entre 1000 e 2000 pés quadrados na população, então meus colegas devem ter chegado na mesma estimativa que eu achei, ou pelo menos um valor que é próximo da estimativa, pois também foi feita com uma amostra aleatória.



Exercício 5: Retire uma segunda amostra, também de 50 casos sem reposição, e a armazene em um novo objeto chamado **samp2**. Como a estimativa obtida com **samp2** se compara à estimativa na **samp1**? Vamos supor que retiremos mais duas amostras, uma de 100 casos e outra de 1000 casos. Qual você acha que daria uma estimativa mais precisa da média populacional?

A estimativa do **samp2** foi mais próxima que a do **samp1**, sendo o primeiro 1508 e o segundo 1515.

Entre uma amostra de 100 casos e de 1000 casos, a estimativa que seria mais precisa seria a

amostra de 1000 casos. Já que ela estaria levando em conta mais casos e, teoricamente, teria mais chance de pegar os casos que estão próximos da média, aproximando mais a estimativa.

Exercício 6: Faça um histograma de *means50* e verifique se ele é semelhante ao histograma acima. Se você quiser ajustar a largura do segmento do seu histograma para exibir um pouco mais de detalhes, você pode fazê-lo mudando o argumento *breaks*.



Eles são relativamente parecidos, mas a barrinha que é mais alta no gráfico azul fica antes de 1500 e a do gráfico rosa, depois de 1500. Os extremos dos dois gráficos e as barrinhas, que conforme vão se aproximando ao meio, também estão similares.

Exercício 7: A variável *means50* contém quantos elementos? Descreva a distribuição amostral, e certifique-se de prestar atenção especificamente em seu centro. Você acha que a distribuição mudaria se coletássemos 50.000 amostras e calculássemos as médias amostrais?

Existe 5000 objetos em *means50*. O gráfico de *means50* é simétrico. Se coletássemos 50000 amostras, não acho que o gráfico mudaria muito. Talvez o gráfico ficasse um pouco mais simétrico.

Exercício 8: Para ter uma ideia melhor do efeito do tamanho da amostra na distribuição amostral, vamos construir mais duas distribuições amostrais variando o tamanho da amostra.

a) Gere 5.000 amostras sem reposição de tamanho 10 e 5.000 amostras de tamanho 100. Calcule as médias para cada amostra obtida e salve essas médias em objetos chamados *means10* e *means100*, respectivamente.


b) Apresente os histogramas de *means10*, *means50* e *means100* lado a lado.

c) Quando o tamanho da amostra é maior, o que acontece com o centro da distribuição? E com a dispersão?

a)

```
means10 = replicate(5000, mean(sample(area, 10)))
means100 = replicate(5000, mean(sample(area, 100)))
```

b)



c) A dispersão diminui conforme o tamanho da amostra aumenta. Ou seja, os valores das amostras ficam mais próximas.


Exercício 9: Até esse ponto, focamos em estimar a média da área habitável nas casas do município de Ames. Agora você irá estimar a média dos preços das casas.

- Retire uma amostra aleatória de 50 elementos da variável preço (**price**). Com essa amostra, qual é sua melhor estimativa pontual para a média populacional?
- Já que você tem acesso à população, simule a distribuição amostral de $\bar{x}_{price}$ retirando 5000 amostras de 50 elementos da população e calculando 5000 médias amostrais. Armazene essas médias em um vetor com o nome **means50_price**. Crie um gráfico com os resultados, e então descreva a forma dessa distribuição amostral. Baseado nessa distribuição amostral, qual seria seu palpite para a média dos preços das casas na população? Por fim, calcule e informe a média populacional.
- Aproxime a distribuição amostral de **means50_price** por uma curva normal e apresente isso num gráfico, juntamente com o histograma obtido no item anterior. Qual a média e desvio padrão da distribuição normal?
- Calcule a média e variância verdadeira dos preços, ou seja, à partir dos dados completos. Aplique o Teorema do Limite Central para mostrar que a média amostral deveria se aproximar de que distribuição? Qual a média e variância da distribuição de $\bar{X}_n$?
- Mude o tamanho da sua amostra de 50 para 150, e então calcule a distribuição amostral utilizando o mesmo método descrito acima, e guarde as médias em um novo vetor com o nome **means150_price**. Descreva a forma dessa distribuição amostral e compare-a com a distribuição amostral para a amostra de 50 elementos. Com base nessa distribuição amostral, qual seria seu palpite sobre a média dos preços de vendas de casas no município de Ames?
- Das distribuições amostrais calculadas nos itens b) e e), qual tem menor dispersão? Se estamos interessados em estimativas que estão mais próximas do valor verdadeiro, preferiríamos uma distribuição com uma dispersão pequena ou grande?

a)

```
> summary(samp_price)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 62383 113500 156466 187971 243500 415000
```

b)




O gráfico é simétrico. Tendo a parte mais com maior frequência entre 175000 e 185000. Meu palpite é de que média dos preços das casas, na população, deve ficar próxima de 180000.

$$\text{Média populacional} = \mu = \frac{1}{n} \sum_{i=1}^n X_i = 180796,1$$

```
> mean(price)
[1] 180796.1
```

c)



$$\text{Desvio padrão} = \sigma = \sqrt{\mathbb{E}[\bar{X} - \mathbb{E}(\bar{X})]^2} = 11332,34$$

```
> sd(means50_price)
[1] 11332.34
```

$$\text{Média} = \bar{X} = 180703,1$$

```
> mean(means50_price)
[1] 180703.1
```


$$\text{d) Média populacional} = \mu = \frac{1}{n} \sum_{i=1}^n X_i = 180796,1$$

```
> mean(price)
[1] 180796.1
```

$$\text{Desvio padrão} = 79886,69$$

```
> sd(price)
[1] 79886.69
```

e)



```
> mean(means150_price)
[1] 180826.5
> sd(means150_price)
[1] 6329.864
```

O gráfico é simétrico, em que o centro é o intervalo entre 180000 e 182000.

Comparado com o gráfico de means50_price, ela parece estar mais distribuída, sendo que o pico do primeiro gráfico ficou próximo da frequência de 800 e o do means150_price ficou próximo de 600.

Meu palpite em relação ao gráfico ao lado é de que o preço de venda das casas é próximo de 180000.

f) Entre as distribuições calculadas nos itens b) e e), o item e) tem menor dispersão. Para achar valores próximos ao verdadeiro, é preferível o valor que possui uma dispersão menor. Já que quanto maior a dispersão, mais longe do resultado real o valor estimado está.