

ME111 - Atividade 08

Profa. Tatiana Benaglia

17/06/2020 - 1S2020

Fundamentos de Inferência - Distribuição Amostral

Nessa atividade, vocês irão trabalhar com conceitos de inferência estatística como estimativa pontual e distribuição amostral.

Estudaremos como uma estatística de uma amostra aleatória de dados podem servir como estimativa pontual de um parâmetro populacional como, por exemplo, a média ou uma proporção. Além disso, estamos interessados em estudar a distribuição dessa estatística, a **distribuição amostral**, para entender melhor seu comportamento e poder usá-la para tirar conclusões sobre a população.

Ao final dessa atividade, o aluno deverá:

- entender o conceito de amostra aleatória e sua importância;
- entender o que é uma estatística e uma estimativa pontual;
- entender o conceito de distribuição amostral;
- saber realizar uma simulação para estimar a distribuição amostral de uma estatística;
- realizar essas simulações no R.

Os Dados

Vamos analisar dados do setor imobiliário da cidade de Ames, no estado de Iowa, Estados Unidos. Os detalhes de cada transação imobiliária na cidade de Ames é registrada pelo escritório da Secretaria Municipal da Receita da cidade. Nosso foco particular para este laboratório será todas as vendas de casa em Ames entre 2006 e 2010. Essa coleção representa nossa população de interesse. Neste laboratório queremos aprender sobre essas vendas de casa retirando pequenas amostra da população completa. Para importar os dados, iremos primeiro baixá-lo da internet e depois carregá-lo no R. Isso é feito através dos comandos a seguir:

```
## download.file("http://www.openintro.org/stat/data/ames.RData", destfile = "ames.RData")  
  
load("ames.RData")
```

Depois que o arquivo for baixado uma primeira vez, ele será armazenado no seu computador em um arquivo chamado **ames.RData** e, então, vocês podem comentar a primeira linha do código acima.

Explore esse conjunto de dados para verificar o número de observações, as variáveis, etc. Para isso, podem usar o comando:

```
str(ames)
```

Vemos que há muitas variáveis em nosso conjunto de dados, o suficiente para realizar uma análise mais aprofundada. Para essa atividade, restringiremos nossa atenção para somente duas variáveis: a área habitável da casa acima do nível do solo em pés quadrados (**Gr.Liv.Area**) e o preço da venda (**SalePrice**). Para economizar esforços ao longo da atividade, armazene essas colunas em dois vetores distintos com nomes curtos para representar essas duas variáveis do conjunto de dados.

```
area = ames$Gr.Liv.Area  
price = ames$SalePrice
```

Exercício 1: Vamos dar uma olhada na distribuição da área em nossa população de vendas de casas calculando algumas estatísticas sumárias e criando um histograma usando as funções `summary()` e `hist()`, respectivamente. Descreva a distribuição da população.

A Distribuição Amostral Desconhecida

Veja que nós temos acesso à população inteira, mas isso raramente acontece na vida real. Reunir informação sobre uma população inteira costuma ser muito custoso ou impossível. Por essa razão, frequentemente retiramos uma amostra da população e a utilizamos para compreender propriedades da população.

Se estivermos interessados em estimar a área habitável média na cidade de Ames com base numa amostra, podemos fazer isso usando o seguinte comando:

```
set.seed(11111) ## troque o número 11111 pelo seu RA
samp1 = sample(area, 50)
```

Esse comando retira uma amostra aleatória simples sem reposição de tamanho 50 do vetor `area`, e é armazenada no objeto `samp1`. O argumento que determina se a amostra será retirada com ou sem reposição é o `replace`.

Esse procedimento é como se fôssemos ao banco de dados da Secretaria Municipal da Fazenda e retirássemos os arquivos de 50 vendas de casas aleatoriamente. Trabalhar com esses 50 arquivos seria consideravelmente mais simples do que lidar com todas as 2930 vendas de casas.

Exercício 2: Descreva a distribuição desta amostra. Como ela se compara à distribuição da população?

Exercício 3: Se estamos interessados em estimar a área habitável média nas casas da cidade de Ames utilizando esta amostra, qual estatística você recomendaria? Calcule e reporte a sua estimativa.

Exercício 4: Dependendo de quais foram as 50 casas sorteadas, ou seja, com uma amostra de menos de 3% da população, sua estimativa pode estar um pouco acima ou abaixo da média populacional verdadeira de 1500 pés quadrados. Você acha que obteve uma boa estimativa? Você acha que seus colegas obtiveram uma estimativa melhor ou pior que a sua?

Exercício 5: Retire uma segunda amostra, também de 50 casos sem reposição, e a armazene em um novo objeto chamado `samp2`. Como a estimativa obtida com `samp2` se compara à estimativa na `samp1`? Vamos supor que retiremos mais duas amostras, uma de 100 casos e outra de 1000 casos. Qual você acha que daria uma estimativa mais precisa da média populacional?

Não é surpreendente que, a cada vez que retiramos uma nova amostra aleatória, obtemos uma média amostral diferente. É útil ter uma ideia de quanta variabilidade podemos esperar quando estimamos a média populacional desta maneira. A distribuição das médias amostrais, denominada de *distribuição amostral*, pode nos ajudar a compreender essa variabilidade.

Nesta atividade, uma vez que temos acesso à população, podemos elaborar a distribuição amostral para a média amostral repetindo os passos acima muitas vezes. Agora geraremos 5000 amostras e calcularemos a média amostral de cada uma.

```
means50_loop = rep(0, 5000)


for(i in 1:5000){
  samp = sample(area, 50)
  means50_loop[i] = mean(samp)
}
```

Vamos agora apresentar o histograma das médias amostras para as 5.000 amostras.


```
par(mfrow = c(1, 2)) ## gráficos serão apresentados lado a lado (1 linha, 2 colunas)
hist(means50_loop, col="lightblue", las = 1, main = "Nº intervalos = automático")
```

```
hist(means50_loop, col="lightblue", las = 1, breaks = 20,
     main = "Nº intervalos = 20")
```

Nº intervalos = automático



Nº intervalos = 20



O argumento `breaks` especifica o número de intervalos utilizados para construir o histograma. No gráfico da direita, temos o

Veja que cada interação do loop executa exatamente os mesmos comandos. Então, podemos substituir as várias linhas de código acima que formam o loop por apenas uma linha de comando através da função `replicate()`. Ou seja,

```
means50 = replicate(5000, mean(sample(area, 50)))
```

Resumindo: Nós utilizamos o R para retirar 5000 amostras sem reposição de 50 casos da população geral, calcular a média de cada amostra, e registrar cada resultado num vetor denominado `means50`. Isso é exatamente o que o código acima está executando.

Exercício 6: Faça um histograma de `means50` e verifique se ele é semelhante ao histograma acima. Se você quiser ajustar a largura dos segmentos do seu histograma para exibir um pouco mais de detalhes, você pode fazê-lo mudando o argumento `breaks`.

Exercício 7: A variável `means50` contém quantos elementos? Descreva a distribuição amostral, e certifique-se de prestar atenção especificamente em seu centro. Você acha que a distribuição mudaria se coletássemos 50.000 amostras e calculássemos as médias amostrais?

Tamanho da Amostra e Distribuição Amostral

A distribuição amostral que calculamos nos informa bastante sobre as estimativas da área habitável nas casas na cidade de Ames. Uma vez que a média amostral é um estimador não-viesado, a distribuição amostral está centrada na verdadeira média da área habitável da população, e a dispersão da distribuição indica quanta variabilidade é possível ao se amostrar somente 50 vendas de casas.

Exercício 8: Para ter uma ideia melhor do efeito do tamanho da amostra na distribuição amostral, vamos construir mais duas distribuições amostrais variando o tamanho da amostra.

- Gere 5.000 amostras sem reposição de tamanhos 10 e 5.000 amostra de tamanho 100. Calcule as médias para cada amostra obtida e salve essas médias em objetos chamados `means10` e `means100`, respectivamente.

```
means10 =  
means100 =
```

- b) Apresente os histogramas de `means10`, `means50` e `means100` lado a lado.
- c) Quando o tamanho da amostra é maior, o que acontece com o centro da distribuição? E com a dispersão?

Estimando a média dos preços

Exercício 9: Até esse ponto, focamos em estimar a média da área habitável nas casas do município de Ames. Agora você irá estimar a média dos preços das casas.

- a) Retire uma amostra aleatória de 50 elementos da variável preço (`price`). Com essa amostra, qual é sua melhor estimativa pontual para a média populacional?
- b) Já que você tem acesso à população, simule a distribuição amostral de $\bar{x}_{price}$ retirando 5000 amostras de 50 elementos da população e calculando 5000 médias amostrais. Armazene essas médias em um vetor com o nome `means50_price`. Crie um gráfico com os resultados, e então descreva a forma dessa distribuição amostral. Baseado nessa distribuição amostral, qual seria seu palpite para a média dos preços das casas na população? Por fim, calcule e informe a média populacional.
- c) Aproxime a distribuição amostral de `means50_price` por uma curva normal e apresente isso num gráfico, juntamente com o histograma obtido no item anterior. Qual a média e desvio padrão da distribuição normal?
- d) Calcule a média e variância verdadeira dos preços, ou seja, à partir dos dados completos. Aplique o Teorema do Limite Central para mostrar que a média amostral deveria se aproximar de que distribuição? Qual a média e variância da distribuição de $\bar{X}_n$?
- e) Mude o tamanho da sua amostra de 50 para 150, e então calcule a distribuição amostral utilizando o mesmo método descrito acima, e guarde as médias em um novo vetor com o nome `means150_price`. Descreva a forma dessa distribuição amostral e compare-a com a distribuição amostral para a amostra de 50 elementos. Com base nessa distribuição amostral, qual seria seu palpite sobre a média dos preços de vendas de casas no município de Ames?
- f) Das distribuições amostrais calculadas nos itens b) e c), qual tem menor dispersão? Se estamos interessados em estimativas que estão mais próximas do valor verdadeiro, preferiríamos uma distribuição com uma dispersão pequena ou grande?