


Exercício 1: Descreva a distribuição da sua amostra. Qual é o tamanho de casa típico dentro da sua amostra? Procure esclarecer também como você interpretou o significado de típico.



A distribuição é assimétrica, onde a concentração está à esquerda. Sendo o Primeiro e Terceiro Quartis, respectivamente, 1047 e 1626 pés quadrados. O tamanho de casa típico dentro da amostra é próximo de 1300 pés quadrados. Como é mostrado pelo gráfico ao lado, a frequência do tamanho das casas esta concentrada entre 1300 e 1600 pés quadrados, sendo que o pico, ou seja, onde a frequência é maior está entre 1300 e 1400 pés quadrados. Desse modo, na amostra existem mais casas que possuem a área próxima desse intervalo.

Exercício 2: Você acha que a distribuição de outro aluno seria idêntica a sua? Você acha que ela seria similar? Por quê, ou por que não?

A distribuição de outra pessoa seria diferente, já que a amostra é retirada aleatoriamente com os valores reais das casas e a população original é muito grande. Além do fato de que a amostra feita possui apenas 60 casas.

Exercício 3: Para o intervalo de confiança ser válido, a média amostral precisa ter distribuição normal e ter um erro padrão igual a $s/\sqrt{n}$. Quais condições precisam ser atendidas para isso ser verdadeiro? Desvio padrão amostral (s)

A amostra precisa ser grande, no mínimo maior que 30, e aleatorizada, sendo “ s ” o desvio padrão amostral. Além de a distribuição da população deve ser simétrica.

Exercício 4: O que significa 95% de confiança?

O nível de confiança representa a porcentagem de intervalos que iriam incluir o parâmetro populacional desejado ou analisado se reunisse amostras da mesma população várias vezes. Desse modo, 95% de confiança significa que se tivéssemos coletado 100 amostras da população e calculado 95% de intervalos de confiança, esperaríamos que aproximadamente 95 dos intervalos contivesse o parâmetro populacional desejado.

Exercício 5: Nesta atividade, nós temos a vantagem de saber a verdadeira média populacional, uma vez que temos os dados da população inteira. Calcule a média população do tamanho das casas.

```
> mean(area_pop)
[1] 1499.69
```

$$\text{Média} = \frac{1}{n} \sum_{i=1}^n a_i = 1499,69$$

Sendo: n = número total (da população) ; a_i = o valor que cada “indivíduo” possui, no caso o tamanho da casa.

Exercício 6: O seu intervalo de confiança contém a verdadeira média do tamanho das casas em Ames? Será que o intervalo obtido pelos seus colegas também contém esse valor?

```
> z
[1] 1.959964
> se_06
[1] 59.71555
> margem_06
[1] 117.0403
> lower_06
[1] 1283.026
> upper_06
[1] 1517.107
> ic_06
[1] 1283.026 1517.107
```

O intervalo de confiança contém a verdadeira média do tamanho das casas em Ames, pois o intervalo obtido é 1283,026 ~ 1517,107 e a média populacional é 1499,69.

O intervalo obtido por outras pessoas, provavelmente, também contém a média. Já que, a amostra foi retirada da mesma população e assim, a frequência em que os valores das casas da amostra podem ser parecidos, então teria chances de conseguir um intervalo parecido. Mesmo que também exista chances de obter um intervalo que não contenha o valor da média populacional.

Exercício 7: Cada aluno de sua turma deve ter obtido um intervalo de confiança um pouco diferente. Suponha que 70 alunos calcularam os intervalos. Quantos desses intervalos você espera que contenha a verdadeira média populacional? Por quê? Acredito que entre 66 e 67 intervalos conteriam a verdadeira média populacional, pois, em teoria, 95% dos intervalos obtidos pelos alunos teriam o valor verdadeiro contido.

Exercício 8: Utilizando o R, vamos criar várias amostras para aprender um pouco mais a respeito de como as médias amostrais e os intervalos de confiança variam de uma amostra para outra.


Execute o seguinte processo iterativo:

- 1) Obter uma amostra aleatória.
- 2) Calcular a média e o desvio padrão da amostra.
- 3) Utilizar estas estatísticas e calcule um intervalo de confiança.
- 4) Repetir as etapas (1)-(3) 50 vezes. (1, 2 e 3)
- 5) Armazenar esses 50 intervalos de confiança.

```
Amostra_média = rep(NA, 50)
Amostra_desvio = rep(NA, 50)
n = 60
for(i in 1:50){ # "for" é um loop; de "i" variando de 1 a 50
  amostra = sample(area_pop, n)
  Amostra_média[i] = mean(amostra) # O "[i]" é a posição
  Amostra_desvio[i] = sd(amostra)
}
```

```
> Amostra_média
[1] 1517.950 1533.000 1578.717 1531.717 1461.883 1598.117 1419.133 1374.367 1461.700 1403.500 1519.433 1558.183 1398.183
[14] 1491.467 1496.867 1499.600 1583.317 1508.300 1517.183 1482.767 1436.183 1458.833 1487.617 1443.483 1484.667 1483.717
[27] 1480.950 1629.950 1542.733 1448.667 1486.617 1583.683 1437.950 1591.817 1519.550 1469.617 1515.567 1531.717 1579.100
[40] 1525.317 1572.900 1424.700 1489.100 1529.950 1435.900 1512.283 1611.917 1600.417 1525.833 1535.467
> Amostra_desvio
[1] 458.0808 683.2769 545.6863 566.2996 489.6553 603.2560 409.9543 461.3053 520.3154 407.7715 470.7451 510.0867 446.4669
[14] 485.9197 474.7497 516.3480 682.4627 509.8285 477.1031 500.2114 508.6814 439.2225 535.6604 481.0913 526.9692 498.6758
[27] 419.8554 495.8368 542.4589 503.7229 461.9864 598.3936 452.3134 505.9667 659.0056 401.5811 618.9873 578.7609 497.8273
[40] 458.8124 514.3399 428.7055 510.5038 484.8050 454.7656 489.3759 497.0280 667.1119 419.6951 522.4061
> Amostra_média - 1.96 * Amostra_desvio / sqrt(n)
[1] 1402.040 1360.107 1440.639 1388.423 1337.983 1445.472 1315.401 1257.640 1330.042 1300.320 1400.318 1429.114 1285.212
[14] 1368.512 1376.738 1368.946 1410.630 1379.296 1396.460 1356.196 1307.469 1347.695 1352.076 1321.750 1351.325 1357.534
[27] 1374.712 1504.486 1405.472 1321.207 1369.718 1432.269 1323.499 1463.789 1352.799 1368.003 1358.941 1385.270 1453.132
[40] 1409.221 1442.754 1316.223 1359.925 1407.277 1320.828 1388.454 1486.151 1431.614 1419.636 1403.280
> Amostra_média + 1.96 * Amostra_desvio / sqrt(n)
[1] 1633.860 1705.893 1716.794 1675.010 1585.783 1750.761 1522.866 1491.093 1593.358 1506.680 1638.548 1687.253 1511.155
[14] 1614.421 1616.995 1630.254 1756.004 1637.304 1637.907 1609.338 1564.897 1569.972 1623.157 1565.216 1618.008 1609.899
[27] 1587.188 1755.414 1679.994 1576.126 1603.515 1735.098 1552.401 1719.844 1686.301 1571.231 1672.192 1678.163 1705.068
[40] 1641.412 1703.046 1533.177 1618.275 1652.623 1550.972 1636.113 1737.682 1769.219 1632.031 1667.654
```

Exercício 9: Observe que, ao carregar os dados, uma função chamada `plot_ci()` também foi carregada no R. Utilizando essa função, crie um gráfico de todos os intervalos. Que proporção dos intervalos de confiança contém a verdadeira média populacional? Essa proporção é exatamente igual ao nível de confiança? Se não, explique por quê.



$\frac{2}{50} = \frac{4}{100} = 4\%$ dos intervalos não possui a verdadeira média populacional. Não é igual ao nível de confiança, que é 95%, mas ela é próxima, pois a amostra é pequena para ter 5% que não contém a média real. Sabendo que para que isso ocorresse seria necessário $\frac{5}{100} = \frac{2,5}{50}$, sendo assim deveria haver 2,5 intervalos, mas não há um número de intervalos quebrado, só inteiros.

Exercício 10: Agora é sua vez de escolher um nível de confiança de sua preferência, algo diferente de 95%. Qual é o valor crítico obtido na tabela normal para esse nível de confiança? Que influência isso tem na margem de erro?

Nível de confiança = 90%


O valor crítico obtido na tabela normal é 1,64

A margem de erro diminui, ou seja, apenas 90% dos intervalos feitos contém o valor verdadeiro.

Além de o intervalo diminuir junto.

Exercício 11: Calcule 50 intervalos de confiança utilizando o nível de confiança escolhido por você. Você não precisa obter novas amostras: simplesmente calcule os novos intervalos baseado nas médias amostrais e desvios padrão que você já coletou.

Utilizando a função `plot_ci()`, crie gráficos de todos os intervalos e calcule a proporção de intervalos que contém a verdadeira média populacional. Compare essa proporção com o nível de confiança escolhido para os intervalos.



$\frac{5}{50} = \frac{10}{100} = 10\%$ dos intervalos não contém o valor verdadeiro da média populacional.

O nível de confiança escolhido foi 90%, sendo assim, teoricamente, 10% dos intervalos calculados não teriam a média populacional, o que acabou sendo verdade, já que os intervalos calculados, apenas 5 deles não contem a média real, o que corresponde a 10%.