

ME111 - Atividade 09

Profa. Tatiana Benaglia

01/07/2020 - 1S2020

Fundamentos de Inferência - Intervalo de Confiança

Nessa atividade, vocês irão trabalhar com conceitos de inferência estatística como estimativa pontual e intervalo de confiança para a média populacional.

Ao final dessa atividade, o aluno deverá:

- entender o que é uma estatística e uma estimativa pontual;
- entender o conceito de distribuição amostral;
- calcular intervalos de confiança para a média populacional.

Introdução

Se você tem acesso aos dados de uma população inteira, por exemplo o tamanho de cada casa na cidade de Ames, Iowa, Estado Unidos, é fácil e direto responder a questões como “Qual é o tamanho de uma casa típica na cidade de Ames?” e “Quanta variação existe no tamanho das casas?”. Se você tem acesso somente a uma amostra da população, como costuma ser o caso, responder a essas perguntas fica mais complicado. Qual é sua melhor estimativa para o tamanho típico de uma casa se você só sabe o tamanho de algumas dezenas de casas? Esse tipo de situação requer que você use sua amostra para fazer inferências a respeito da população em geral.

Os Dados

Na atividade anterior nós exploramos os dados populacionais das casas da cidade de Ames, Iowa. Vamos começar carregando esse mesmo conjunto de dados.

```
## download.file("http://www.openintro.org/stat/data/ames.RData", destfile = "ames.RData")  
  
load("ames.RData")
```

Nessa atividade, começaremos com uma amostra aleatória simples de 60 elementos da população. Perceba que o conjunto de dados contém informações sobre várias variáveis relativas às casas, mas para a primeira parte do laboratório focaremos no tamanho da casa, representada pela variável `Gr.Liv.Area`.

```
area_pop = ames$Gr.Liv.Area  
area = sample(area_pop, 60)
```

Exercícios - Intervalos de confiança

Exercício 1: Descreva a distribuição da sua amostra. Qual é o tamanho de casa *típico* dentro da sua amostra? Procure esclarecer também como você interpretou o significado de *típico*.

Exercício 2: Você acha que a distribuição de outro aluno seria idêntica a sua? Você acha que ela seria similar? Por quê, ou por quê não?

Uma das maneiras mais comuns para se descrever o valor típico ou central de uma distribuição é por meio da média. Neste caso, podemos calcular a média da amostra utilizando a função `mean()`.

```
media_area = mean(???)
```

Retome agora a pergunta que motivou esta atividade: baseado nesta amostra, o que podemos inferir sobre a população?

Com uma única amostra, a melhor estimativa da área habitacional das casas vendidas em Ames seria a média amostral, geralmente representada como $\bar{x}$ (aqui denotada por `media_area`). A média amostral serve como uma boa **estimativa pontual**, mas seria interessante também especificar quanta incerteza temos ao redor dessa estimativa. Isso pode ser feito pelo uso de um **intervalo de confiança**.

Podemos calcular um intervalo de confiança de 95% para a média amostral adicionando e subtraindo uma **margem de erro**, ou seja, 1.96 erros padrão da estimativa pontual. Esse valor 1.96 é o valor crítico obtido na distribuição normal de acordo com o nível de significância.

```
alpha = 0.05
z = qnorm(1 - alpha/2)
se = sd(area)/sqrt(60)
margem = z * se
lower = media_area - margem
upper = media_area + margem
ic = c(lower, upper)
```

Acabamos de fazer uma inferência importante: mesmo que não saibamos como a população inteira se distribui, temos 95% de confiança de que o intervalo com limites `lower` e `upper` contém a média verdadeira do tamanho das casas em Ames. O importante aqui é notar que o intervalo é que é aleatório. Contudo, existem algumas condições que precisam ser atendidas para esse intervalo ser válido.

Exercício 3: Para o intervalo de confiança ser válido, a média amostral precisa ter distribuição normal e ter um erro padrão igual a $s/\sqrt{n}$. Quais condições precisam ser atendidas para isso ser verdadeiro?

Exercício 4: O que significa **95% de confiança**?

Exercício 5: Nesta atividade, nós temos a vantagem de saber a verdadeira média populacional, uma vez que temos os dados da população inteira. Calcule a média população do tamanho das casas.

Exercício 6: O seu intervalo de confiança contém a verdadeira média do tamanho das casas em Ames? Será que o intervalo obtido pelos seus colegas também contém esse valor?

Exercício 7: Cada aluno de sua turma deve ter obtido um intervalo de confiança um pouco diferente. Suponha que 70 alunos calcularam os intervalos. Quantos desses intervalos você espera que contenha a verdadeira média populacional? Por quê?

Exercício 8: Utilizando o R, vamos criar várias amostras para aprender um pouco mais a respeito de como as médias amostrais e os intervalos de confiança variam de uma amostra para outra.

Execute o seguinte processo iterativo:

1. Obter uma amostra aleatória.
2. Calcular a média e o desvio padrão da amostra.
3. Utilizar estas estatísticas e calcule um intervalo de confiança.

4. Repetir as etapas (1)-(3) 50 vezes.
5. Armazenar esses 50 intervalos de confiança.

Dica: Armazene os limites inferiores e superiores destes 50 intervalos de confiança em variáveis com nomes `limInf` e `limSup`, respectivamente. Isso será útil para fazer o próximo gráfico.

Exercício 9: Observe que, ao carregar os dados, uma função chamada `plot_ci()` também foi carregada no R. Utilizando essa função, crie um gráfico de todos os intervalos. Que proporção dos intervalos de confiança contém a verdadeira média populacional? Essa proporção é exatamente igual ao nível de confiança? Se não, explique por quê.

Exercício 10: Agora é sua vez de escolha um nível de confiança de sua preferência, algo diferente de 95%. Qual é o valor crítico obtido na tabela normal para esse nível de confiança? Que influência isso tem na margem de erro?

Exercício 11: Calcule 50 intervalos de confiança utilizando o nível de confiança escolhido por você. Você não precisa obter novas amostras: simplesmente calcule os novos intervalos baseado nas médias amostrais e desvios padrão que você já coletou. Utilizando a função `plot_ci()`, crie gráficos de todos os intervalos e calcule a proporção de intervalos que contém a verdadeira média populacional. Compare essa proporção com o nível de confiança escolhido para os intervalos.